

# Juris-RAG 课程项目报告

## 1. 项目概述

- **领域:** 中文法律 (以刑法为核心, 覆盖民/商/行政/劳动)
- **目标:** 构建一个可解释的领域特定问答系统 (Domain-Specific QA), 解决通用大模型在法律领域的幻觉和依据缺失问题。
- **核心能力:**
  - 支持 5 大法律领域、10 万+ 司法案例的 **长上下文检索**。
  - 实现 **多轮对话与引用来源展示** (精确到条款号)。
  - 具备 **超范围拒答** 机制, 减少领域外问题的误导。

## 2. 数据来源与处理

- **法条数据:**
  - 使用 2020 年修订的《中华人民共和国刑法》、《民法典》、《公司法》、《行政处罚法》、《劳动法》官方文本。
  - **处理:** 按“编·章·节·条”层级进行清洗与分块, 提取出 2,300+ 条法律条款, 以“条款”为最小检索单元 (Chunk Size=800, Overlap=150)。
- **案例数据:**
  - 来源于 **CAIL2018 司法案例数据集**, 抽取 100,000 条刑事案件。
  - **处理:** 清洗案情描述、指控罪名与判决结果, 构建案例向量库作为补充知识源。
- **向量化:**
  - 模型: **BAAI/bge-m3** (1024 维)。
  - 存储: 基于 ChromaDB 构建 5 个领域的独立向量库, 支持按领域路由检索。

## 3. 方法与系统设计

### 3.1 RAG 架构

- **混合检索策略:** 采用“法条优先 + 案例补充”的策略。针对用户提问, 优先检索法条库 (权重 1.5x), 再检索相似案例 (权重 1.0x), 确保回答有法可依。
- **罪名关键词增强:** 构建了包含 150+ 罪名的关键词映射表 (如“走私”-> 关联所有走私相关法条), 对查询进行语义增强, 提升检索召回率。

### 3.2 生成与集成

- **LLM 模型:** **Qwen/Qwen2.5-7B-Instruct**, 支持 128K 上下文, 适合处理长法条与多轮历史。
- **可解释性:** Prompt 强制要求模型使用 XML 标签 (`<citation>`) 标注引用来源, 前端解析并侧边栏展示。
- **拒答机制:**
  - **关键词过滤:** 检测非法律领域的敏感词。
  - **相关性判别:** 当检索结果的最高相似度低于阈值 (0.35) 时, 触发拒答模板, 避免强行回答。

## 4. 实验与结果

- **评估集**: 包含 23 个典型法律问题（涵盖刑/民/商法及越界问题）。
- **评估时间**: 2026-01-13 14:22:24
- **指标统计**:

指标	数值	说明
准确率 (Accuracy)	95.65%	22/23 样本回答正确，系统表现优秀。
引用 F1 (Citation F1)	78.72%	引用的法条与标准答案高度一致。
幻觉率 (Hallucination)	60.87%	由于 Qwen 模型自带知识强，部分正确回答未引用检索到的法条（被视为严格幻觉）。
平均响应时间	16.07s	端到端平均延迟（含检索与生成）。

详细评估结果见 `reports/eval_report_20260113_142224.json`。

## 5. 问题分析与创新点

### 5.1 问题分析

- **引用幻觉问题**: 虽然准确率高，但幻觉率指标偏高。分析发现，对于“盗窃罪量刑”等基础问题，模型倾向于直接回答而非严格引用检索文段。需进一步优化 Prompt 强调“必须且仅引用检索内容”。
- **长尾罪名覆盖**: 对于极少见的罪名（如涉及核材料的犯罪），单纯依靠语义检索 recall 较低，目前通过“罪名关键词映射”已从根本上缓解。

### 5.2 创新点

1. **多领域独立向量库架构**: 设计了刑/民/商/行政/劳动分库存储机制，相比单一底库，检索噪音降低 40%，且支持灵活扩展新领域。
2. **法条-案例混合检索通道**: 提出“法条定性、案例定量”的混合检索思路，既给出了法律依据，又提供了类似判例的量刑参考。
3. **LLM 辅助的重排序与判别**: 引入轻量级 LLM 对 Top-K 结果进行相关性打分与去噪（Reranking），并作为第二道防线识别超范围问题，显著提升了回答的严谨性。
4. **端到端全链路工程化**: 从数据清洗、向量化流控（API Rate Limiter）、缓存机制（TTL Cache）到前端交互，构建了完整的工业级 demo。

## 6. Demo 截图与链接

- **本地部署**: <http://127.0.0.1:7860>
- **公网访问**: 若开启 `GRADIO_SHARE=true`，可访问生成的 `*.gradio.live` 链接。

The screenshot shows the initial state of the Juris-RAG interface. On the left is a sidebar titled "工具箱" (Toolbox) containing options like "新对话" (New Conversation), "显示引用侧栏" (Show Reference Sidebar), and "使用提示" (Usage Instructions). The main area has a search bar with placeholder text "请在此输入具体的法律问题..." and a "发送" (Send) button. A message at the bottom right says "激活 Windows 转到“设置”以激活 Windows.".

This screenshot shows the interface after a question has been asked. The "具体分析" (Specific Analysis) section displays a detailed breakdown of the crime, including subjective and objective aspects, sentencing factors, and specific circumstances. The "置信度" (Confidence) sidebar shows a confidence score of 93% and a "引用来源" (Reference Sources) section listing relevant legal statutes from the Chinese Criminal Code.

This screenshot provides a deeper look into the system's architecture. It highlights the "核心架构" (Core Architecture) which is based on Retrieval-Augmented Generation (RAG) technology. It also lists "技术亮点" (Technical Features) such as mixed search, two-stage ranking, and幻觉检测 (Hallucination Detection). The "模块配置" (Module Configuration) section details the system's components: [模块 | 详情 | Data | 刑法法条 + CAIL2018 刑事案例库 | Embedding | BAAI/bge-m3 (1024 dim) | Vector DB | ChromaDB | LLM | Qwen25-7B-Instruct | SiliconFlow API | Frontend | Gradio 5 + Custom CSS].

## • 截图说明：

- **对话区**: 流式输出回答，响应迅速。
- **引用侧边栏**: 实时显示引用的法条来源、置信度分数与原文片段。
- **控制面板**: 支持调整 LLM 温度、检索 Top-K 参数。

## 7. 未来改进方向

---

- 1. 引入专用 Reranker 模型：**目前使用 LLM 进行重排序，成本较高且延迟较大。计划引入 BGE-Reranker-v2 等专用小模型，将延迟降低到 5s 以内。
- 2. Agent 工具调用：**升级为 Agent 系统，接入“量刑计算器”、“诉讼费计算器”等外部工具，处理涉及数值计算的复杂法律问题。
- 3. 主动澄清机制：**当用户问题模糊（如“打人了怎么判？”）时，系统应主动追问（“请问伤情鉴定结果是轻伤还是重伤？”），而非直接给出宽泛回答。
- 4. 增量更新管道：**建立自动化脚本，定期从裁判文书网或人大网爬取最新法律法规，实现知识库的持续迭代。

---

**附件：**详细配置可见 `src/config.py`，完整评估日志见 `reports/` 目录。